FIAP · CIÊNCIA DA COMPUTAÇÃO · GLOBAL SOLUTION 2026.2 · CITIZENTECH

Quem usa o ônibus e quem usa o metrô em São Paulo?

Classificação do perfil dos usuários de transporte público com regressão logística, a partir dos microdados da Pesquisa Origem e Destino 2017

Disciplina: Modelagem Linear para Aprendizado de Máquina

Aluno: Lucas Barreto Santana · RM 573149 · Turma 1CCPG

Projeto integrador: Ponto Vivo (Citizen Assist AI)

Entrega: novembro de 2026

1. Introdução

O transporte público por ônibus, metrô e trem é o serviço público usado todos os dias por milhões de moradores de São Paulo. Esses serviços não atendem o mesmo público: a rede de metrô se concentra nas regiões centrais, enquanto o ônibus municipal chega aos bairros periféricos. Conhecer o **perfil de quem usa cada serviço** (sexo, idade, escolaridade, renda, situação de trabalho) ajuda o poder público a decidir **como se comunicar** com cada grupo, **quais direitos divulgar** e **onde investir**.

Este trabalho faz parte do projeto **Ponto Vivo**, um assistente do Citizen Assist AI instalado no ponto de ônibus, que orienta o passageiro sobre tarifas, gratuidades, horários e situações de calor ou alagamento. Saber quem é o passageiro do ônibus, em comparação com o do metrô, define a linguagem e os conteúdos que o assistente deve priorizar.

Objetivo: construir um modelo de aprendizado de máquina que classifique, a partir do perfil de uma pessoa, qual serviço público de transporte ela usa (ônibus municipal da SPTrans, Metrô ou trem da CPTM), e identificar quais características mais pesam nessa diferença.

2. Metodologia

2.1 Escolha da base de dados

Foram avaliadas as bases sugeridas no enunciado. A base da Enap (pesquisa sobre serviços públicos de atendimento do governo federal) descreve os **serviços** oferecidos pelos órgãos, sem dados demográficos dos **usuários**, e por isso não permite classificar perfis. Foi escolhida a **Pesquisa Origem e Destino 2017** da Região Metropolitana de São Paulo, realizada pela Companhia do Metropolitano de São Paulo (Metrô):

- **Dados reais**, coletados em entrevistas domiciliares com cerca de 86 mil pessoas, e públicos;
- **um registro por viagem**, com o modo de transporte usado e os dados de perfil da pessoa e do domicílio;
- cobre **vários serviços públicos** de transporte no mesmo questionário;
- tem o mesmo público do projeto Ponto Vivo: os passageiros de São Paulo.

Fonte: Metrô de São Paulo, Pesquisa Origem e Destino 2017, portal de transparência (transparencia.metrosp.com.br/dataset/pesquisa-origem-e-destino). Os microdados foram obtidos do pacote `odbr` (github.com/hsvab/odbr), que os redistribui sem alteração, porque o portal do Metrô estava indisponível na data da coleta (11/11/2026). O notebook baixa o arquivo e confere a sua impressão digital (SHA-256), para garantir que qualquer execução use exatamente os mesmos dados.

2.2 Pré-processamento

1. **Recorte geográfico:** só moradores do município de São Paulo, onde existem os três serviços e o ônibus municipal é operado pela SPTrans.
2. **Recorte de serviços:** viagens cujo modo principal é metrô, trem ou ônibus municipal de São Paulo. Pela hierarquia da pesquisa, a viagem que usa metrô em algum trecho conta como

metrô.

3. **Uma linha por pessoa:** o serviço da pessoa é o da sua primeira viagem de transporte público no dia, para que quem viaja mais vezes não pese mais. Só 6,7% das pessoas usaram mais de um dos serviços no dia.
4. **Valores ausentes:** 344 pessoas (2,2%) sem a informação de carros no domicílio foram retiradas. A base final tem **14.951 pessoas**.

Variável criada	Origem na pesquisa	Categorias
Sexo	`sexo`	feminino, masculino
Faixa etária	`idade`	até 17, 18 a 29, 30 a 44, 45 a 59, 60 ou mais
Escolaridade	`grau_ins`	fundamental I incompleto, fundamental I completo, fundamental II completo, médio completo, superior completo
Faixa de renda	`renda_fa` ÷ `no_moraf`	renda familiar por pessoa, em salários mínimos de 2017 (R$ 937): até 1/2, 1/2 a 1, 1 a 2, 2 a 3, mais de 3
Situação	`cd_ativi`	trabalha, estudante, aposentado, sem trabalho ou do lar
Carros no domicílio	`qt_auto`	0, 1, 2 ou mais
Serviço (alvo)	`modoprin`	ônibus municipal (4), metrô (1), trem (2)

2.3 Análise estatística

Análise bivariada: para cada característica, foi calculada a proporção de uso de cada serviço e aplicado o **teste qui-quadrado de independência** (H_0: característica e serviço são independentes; nível de significância de 5%). A força da associação foi medida pelo **V de Cramér**.

Análise multivariada: uma regressão logística ajustada com o `statsmodels` fornece, para cada característica, o coeficiente, a **razão de chances** com intervalo de confiança de 95% e o **teste de Wald** (H_0: $\beta = 0$), sempre controlando pelas outras características.

2.4 Construção do modelo

Foi usada a **regressão logística**, o modelo linear de classificação. Ela combina as características com pesos, como uma regressão linear, e transforma o resultado em uma probabilidade com a função logística: $P(\text{metrô}) = 1 / (1 + e^{-(\beta_0 + \beta_1 x_1 + \ldots + \beta_k x_k)})$. Ela foi escolhida porque, além de classificar, permite **interpretar** o peso de cada característica.

- **Modelo principal:** ônibus municipal (0) × metrô (1), os dois serviços com mais usuários (14.292 pessoas).
- **Codificação:** variáveis indicadoras (*one-hot*), com a primeira categoria de cada característica como referência (mulher, até 17 anos, fundamental I incompleto, até 1/2 SM, aposentado, sem carro).
- **Divisão:** 70% para treino e 30% para teste, estratificada, com semente fixa (42).

- **Desbalanceamento:** como há mais usuários de ônibus (60,6%), foi usado `class_weight="balanced"`.
- **Avaliação:** acurácia, acurácia balanceada, precisão, revocação, F1, matriz de confusão e AUC ROC no teste, além de validação cruzada estratificada em 5 partes. A comparação é feita com uma referência que sempre prevê a classe mais frequente.
- **Extensões:** um modelo com a distância da casa até o centro (análise de acesso) e um modelo multinomial com os três serviços.

Ferramentas: Python, pandas, scikit-learn, statsmodels, SciPy e Matplotlib, em notebook Jupyter compatível com o Google Colab.

3. Resultados

3.1 Distribuição dos usuários

Serviço	Pessoas na amostra	% da amostra	População estimada*	% da população
Ônibus municipal	8.655	57,9%	2,06 milhões	62,0%
Metrô	5.637	37,7%	1,07 milhão	32,3%
Trem	659	4,4%	190 mil	5,7%

* Soma do fator de expansão da pesquisa: quantos moradores cada entrevistado representa.

3.2 Perfil por serviço e testes de hipótese

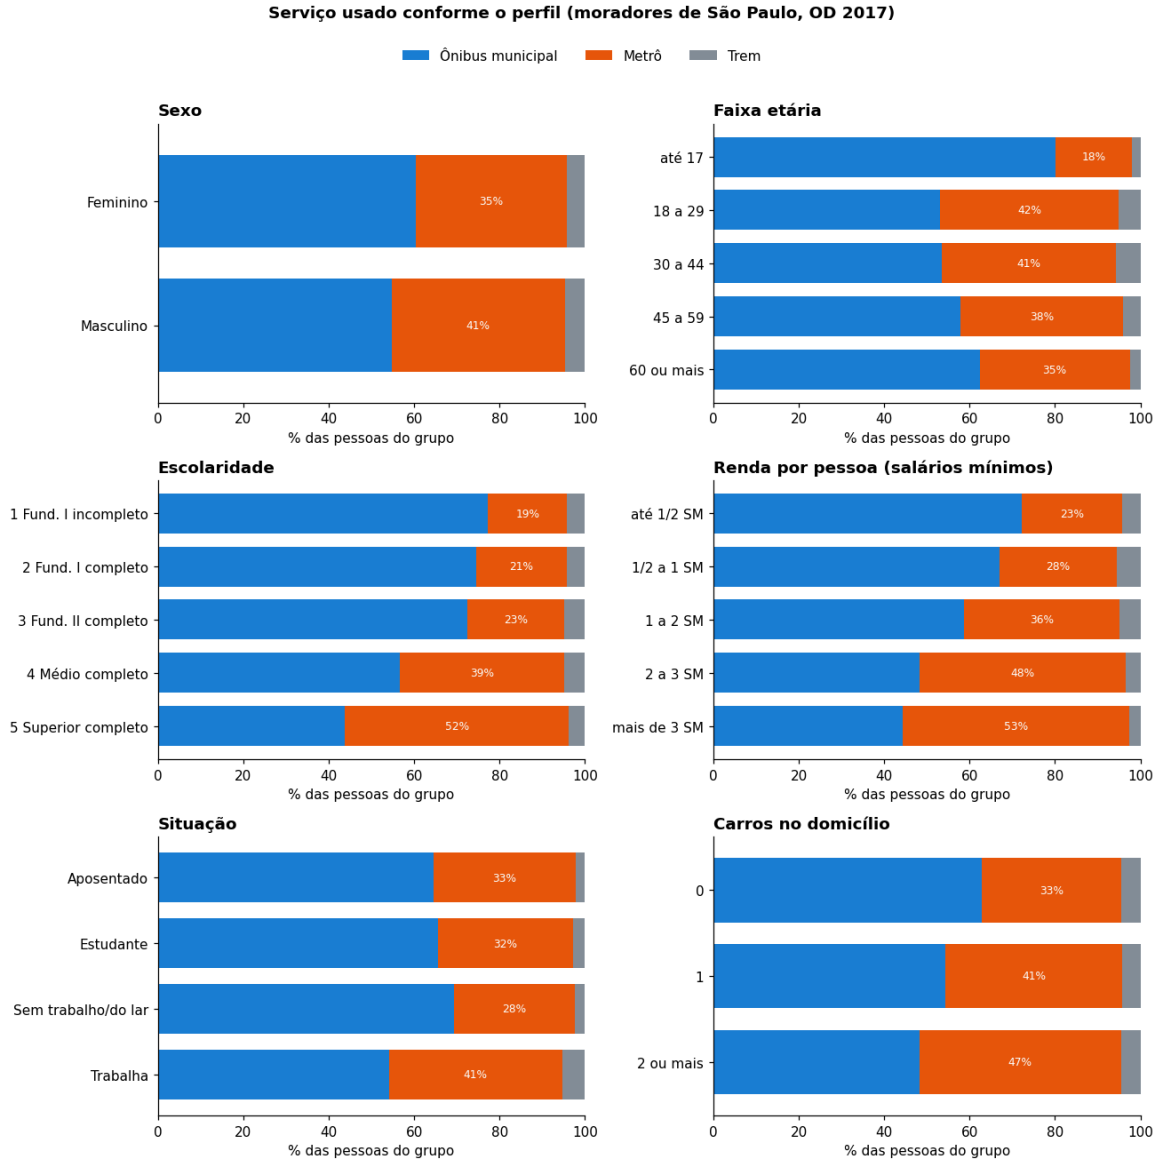


Figura 1. Proporção de cada grupo que usa cada serviço. O número em branco é o percentual de uso do metrô.

Característica	Qui-quadrado	Graus de liberdade	p-valor	V de Cramér	Rejeita H_0?
Escolaridade	921,7	8	$1{,}2 \times 10^{-193}$	0,176	sim
Renda por pessoa	646,2	8	$2{,}7 \times 10^{-134}$	0,147	sim
Faixa etária	357,8	8	$1{,}9 \times 10^{-72}$	0,109	sim
Situação	223,5	6	$1{,}8 \times 10^{-45}$	0,086	sim
Carros no domicílio	175,6	4	$6{,}7 \times 10^{-37}$	0,077	sim
Sexo	47,1	2	$5{,}8 \times 10^{-11}$	0,056	sim

3.3 Desempenho do modelo (ônibus × metrô)

Métrica (conjunto de teste, 4.288 pessoas)	Regressão logística	Referência (sempre ônibus)
Acurácia	0,613	0,606
Acurácia balanceada	0,619	0,500
Precisão (metrô)	0,507	0,000
Revocação (metrô)	0,651	0,000
Revocação (ônibus)	0,588	1,000
F1 (metrô)	0,570	0,000
AUC ROC	0,667	0,500
Validação cruzada (5 partes): acurácia / AUC	0,613 ± 0,007 / 0,668 ± 0,006	—

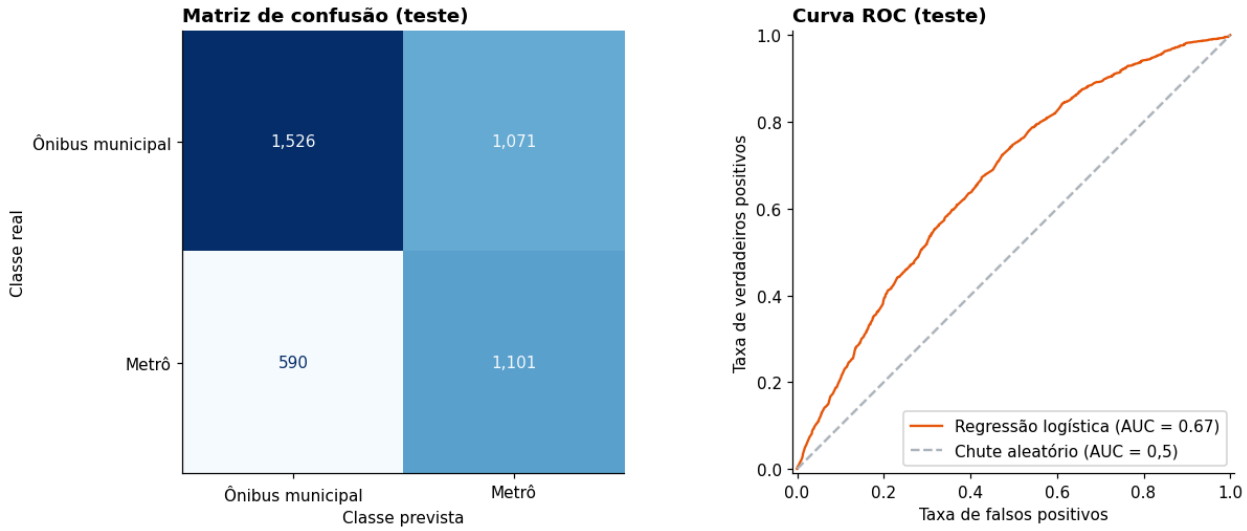


Figura 2. Matriz de confusão e curva ROC no conjunto de teste.

3.4 Peso de cada característica

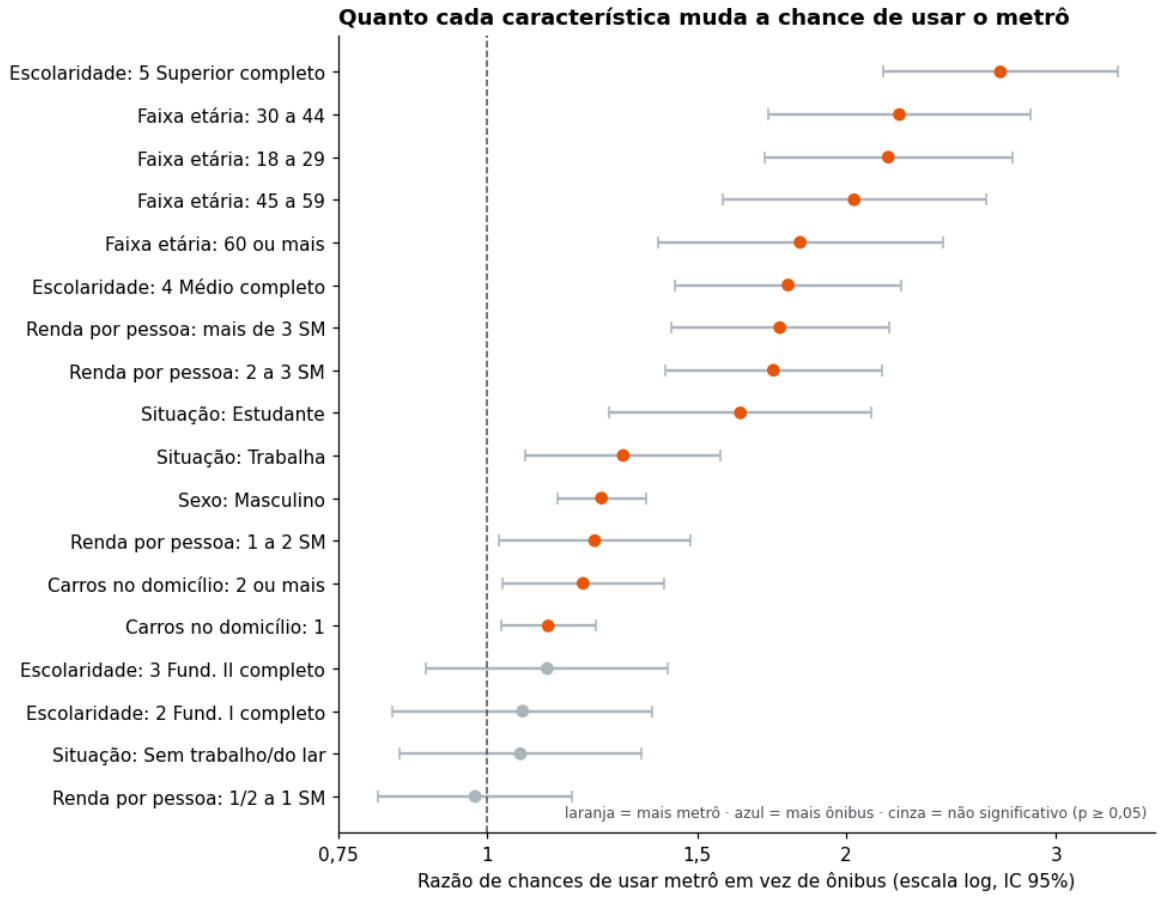


Figura 3. Razões de chances de usar metrô em vez de ônibus, com intervalo de confiança de 95%. Pseudo R^2 de McFadden = 0,064; teste da razão de verossimilhança: $p = 2{,}5 \times 10^{-171}$.

Perfil (exemplo)	P(metrô)	Classe prevista
Mulher, 30 a 44 anos, fundamental I completo, 1/2 a 1 SM, trabalha, sem carro	30%	Ônibus municipal
Homem, 18 a 29 anos, médio completo, 1 a 2 SM, trabalha, sem carro	53%	Metrô
Mulher, 18 a 29 anos, superior completo, mais de 3 SM, trabalha, 1 carro	69%	Metrô
Homem, 60 ou mais, fundamental I incompleto, até 1/2 SM, aposentado, sem carro	25%	Ônibus municipal
Mulher, até 17 anos, fundamental II completo, 1/2 a 1 SM, estudante, 1 carro	23%	Ônibus municipal

3.5 Extensões

Distância da casa até o centro (Sé)	Pessoas	% que usa metrô
até 5 km	3.224	53,3%
5 a 10 km	3.749	45,9%
10 a 15 km	3.098	29,9%
15 a 20 km	2.240	30,8%
mais de 20 km	1.981	29,6%

Modelo (validação cruzada, 5 partes)	AUC ROC	Acurácia balanceada
Só perfil	0,668	0,619
Perfil + distância até o centro	0,676	0,628

Modelo com três serviços (teste)	Precisão	Revocação	F1
Ônibus municipal	0,728	0,346	0,469
Metrô	0,502	0,492	0,497
Trem	0,066	0,530	0,117
Acurácia geral			**0,409**

4. Análise e Discussão

4.1 Os dois públicos são diferentes

As seis características estão associadas ao serviço usado (todos os p-valores muito abaixo de 0,05). Com quase 15 mil pessoas, até associações fracas ficam significativas; por isso o V de Cramér mostra o tamanho de cada efeito. **Escolaridade** (0,176) e **renda** (0,147) são as mais fortes: entre quem não completou o fundamental I, só 19% usam metrô, contra 52% entre quem tem superior completo; na renda, o uso do metrô vai de 23% (até meio salário mínimo por pessoa) a 53% (mais de 3 salários).

Na regressão logística, que controla todas as características ao mesmo tempo, os efeitos se mantêm. Com superior completo, a chance de usar metrô em vez de ônibus é **2,69 vezes** a de quem não completou o fundamental I; adultos têm cerca de **2 vezes** a chance dos menores de 18 anos; renda acima de 2 salários por pessoa aumenta a chance em **1,74 vez**; homens têm **1,25 vez** a chance das mulheres. Os níveis intermediários do fundamental e a faixa de meio a um salário não diferem da referência.

Um resultado que parece contraditório é que ter carro **aumenta** um pouco a chance de usar metrô (1,13 a 1,20). Como a análise inclui só quem usou transporte público, quem tem carro e mesmo assim escolhe o transporte coletivo tende a morar em regiões centrais, com metrô por perto. É um exemplo de como a localização aparece escondida em outras variáveis.

4.2 O modelo separa os públicos, mas com limites

> A acurácia de 61,3% é quase igual à de chutar sempre "ônibus" (60,6%), mas esse chute nunca acerta um usuário de metrô. A **acurácia balanceada** (61,9% contra 50%) e o **AUC de 0,667** mostram que o modelo tem capacidade real, porém **fraca a moderada**, de distinguir os dois públicos.

O modelo encontra 65,1% dos usuários de metrô, mas classifica como metrô 41% dos usuários de ônibus (1.071 de 2.597), e por isso a precisão para o metrô fica em 50,7%. A validação cruzada deu os mesmos valores (acurácia de 0,613 ± 0,007), o que mostra que o resultado é estável e não depende da divisão sorteada. O pseudo R^2 de 0,064 confirma: o perfil é estatisticamente relevante, mas explica uma parte pequena da escolha.

4.3 Perfil ou acesso?

A análise complementar mostra que **onde a pessoa mora pesa tanto quanto quem ela é**. Entre quem mora a até 5 km do centro, 53% usam metrô; a partir de 10 km, cerca de 30%. A distância até o centro é um indicador grosseiro (não sabe que Itaquera, longe do centro, tem estação), e mesmo assim melhora o AUC de 0,668 para 0,676. A distância até a estação mais próxima, que a pesquisa não traz, provavelmente traria um ganho maior.

O modelo de três classes reforça essa conclusão. O trem é usado por só 4,4% das pessoas, e o perfil de quem usa trem é muito parecido com o de quem usa ônibus: a precisão para o trem é de

6,6%. O que define o uso do trem é morar perto de uma linha da CPTM, uma informação que o perfil não carrega.

4.4 Limitações

- Os dados são de 2017; a rede de metrô e os hábitos mudaram desde então (novas estações, pandemia, aplicativos de transporte).
- A pesquisa não informa a distância até a estação mais próxima, o principal fator de acesso.
- O modelo usa a primeira viagem de transporte público do dia; 6,7% das pessoas usaram mais de um serviço.
- O modelo é linear e aditivo: não captura combinações entre características (por exemplo, idade e renda juntas) sem termos de interação.

5. Conclusões

Os microdados da Pesquisa Origem e Destino 2017 mostram que os usuários do **ônibus municipal** e do **metrô** em São Paulo têm perfis diferentes. O passageiro típico do ônibus tem **menos escolaridade e menor renda**, é mais frequentemente **mulher** e inclui a maior parte dos **adolescentes e idosos**. O do metrô tem **ensino médio ou superior completo, renda acima de 2 salários mínimos por pessoa e trabalha ou estuda**. A regressão logística classifica os dois públicos com AUC de 0,67 e acurácia balanceada de 62%, com resultados estáveis, e mostra que **escolaridade, idade e renda** são os fatores de maior peso. Ao mesmo tempo, o perfil explica só parte da escolha: o **acesso**, ou seja, morar perto de uma estação, é decisivo, principalmente para o trem.

Aplicações práticas:

- **Comunicação adequada a cada público:** as informações nos pontos de ônibus devem usar linguagem simples, áudio e atendimento presencial, sem depender só de aplicativos. É a proposta do **Ponto Vivo**, o assistente acessado por QR code no próprio ponto.
- **Divulgação de direitos:** o público do ônibus concentra quem mais tem direito a gratuidades e meia tarifa (idosos, estudantes, baixa renda). O assistente pode destacar essas orientações nos pontos das regiões de menor renda.
- **Planejamento:** expandir o acesso ao metrô e integrar ônibus e trilhos nas regiões periféricas atende justamente o público de menor escolaridade e renda, que hoje depende do ônibus.

Próximos passos: calcular a distância de cada domicílio até a estação mais próxima, testar termos de interação e modelos não lineares (árvores de decisão, florestas aleatórias) e repetir a análise com a Pesquisa Origem e Destino de 2023, quando os microdados estiverem disponíveis.

Referências

- COMPANHIA DO METROPOLITANO DE SÃO PAULO (METRÔ). *Pesquisa Origem e Destino 2017: microdados e dicionário de variáveis*. Disponível em: transparencia.metrosp.com.br/dataset/pesquisa-origem-e-destino.
- *odbr: Download Data from Brazil's Origin Destination Surveys*. Pacote R, versão 0.1.1, 2025. Disponível em: github.com/hsvab/odbr. Arquivo utilizado: od_sao_paulo_2017_not_harmonized.csv.gz (release v0.1.0), acesso

em 11/11/2026.

- ESCOLA NACIONAL DE ADMINISTRAÇÃO PÚBLICA (ENAP). *Base de dados da pesquisa sobre serviços públicos de atendimento do governo federal*. 2018. Disponível em: repositorio.enap.gov.br/handle/1/3695.
- PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- SEABOLD, S.; PERKTOLD, J. statsmodels: Econometric and statistical modeling with Python. In: *Proceedings of the 9th Python in Science Conference*, 2010.

Reprodutibilidade: todos os números deste relatório são gerados pelo notebook `perfil_transporte.ipynb`, entregue no mesmo arquivo ZIP. Ele baixa os dados sozinho e usa semente fixa.